BOĞAZİÇİ ÜNİVERSİTESİ • BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
BİLGİSAYAR MÜHENDİSLİĞİ LİSANS BİTİRME TEZİ

Çok Dilli Eğitim İçin Konuşma Tanıma (ASR), Büyük Dil Modeli (LLM) Tabanlı Terminoloji Çıkarma ve Üretken Video Canlandırma Katmanlarının Üç Katmanlı Değerlendirilmesi

BİTİRME PROJESİ RAPORU • GRADUATION PROJECT FINAL THESIS

ARAŞTIRMACI VE YAZAR

Ali Ayhan Günder (Boğaziçi Üniversitesi)

Jüri Değerlendirme Kurulu	Unvan / Kurum	İmza / Onay
Prof. Dr. Fatih Alagöz Tez Danışmanı	Boğaziçi Üniversitesi Bilgisayar Müh.	.....
Jüri Üyesi	Boğaziçi Üniversitesi Bilgisayar Müh.	.....
Jüri Üyesi	Boğaziçi Üniversitesi Bilgisayar Müh.	.....

İstanbul, Eylül 2026

Özet

Eğitim materyallerinin dijitalleşmesi ve çevrimiçi video platformlarında yaygınlaşması, her düzeydeki öğrenciye zengin bir bilgi havuzu sunmaktadır. Ancak uzmanlık gerektiren ders ve eğitim videoları, dinleyicilerin belirli bir ön bilgiye sahip olduğu varsayımıyla sunulmakta; bu durum başlangıç düzeyindeki öğrenciler için terminolojik ve kavramsal anlama engelleri oluşturmaktadır. Bu bitirme çalışmasında, çok dilli (Türkçe ve İngilizce) eğitim konuşmalarını yeni başlayanlar için erişilebilir kılmayı amaçlayan, hazır (off-the-shelf) otomatik konuşma tanıma (ASR), büyük dil modeli (LLM) ve üretken video canlandırma bileşenlerinin üç katmanlı deneysel değerlendirmesi gerçekleştirilmiştir.

Birinci katmanda, modern konuşma tanıma mimarileri (Whisper Medium, Large-v3, Large-v3 Turbo, Türkçe uyarlanmış Whisper Turbo, Qwen3-ASR 0.6B/1.7B ve NVIDIA Nemotron 3.5 ASR) kelime hata oranı (WER), karakter hata oranı (CER), gecikme ve gerçek zamanlılık katsayısı (RTF) açısından GPU üzerinde altın referanslarla test edilmiştir. Yedi klibin tamamında ölçülen akustik ön-işleme müdahaleleri (enerji tabanlı VAD, terim alan koşullama, LLM düzeltme) makro WER'i ham tabanın aşağısına indirememiştir (TR 0,021 → 0,134); koşullama kademesi altın listeyi girdiye enjekte ettiği için ayrıca ölçüm sızıntısıdır. İkinci katmanda, transkripsiyon çıktıları LLM katmanına (GPT-4.1, GPT-4o-mini, Qwen3.5 modelleri) beslenerek alana özgü çok kelimeli terminolojinin tespiti ve CEFR B1 düzeyinde açıklamaların üretimi sağlanmıştır. Semantik çıktılar; bağlam uyumluluğu (R) ve açıklama doğruluğu (D) boyutlarında değerlendirilmiştir. Üçüncü katmanda semantik çıkarım, açık kaynaklı Manimator mimarisi uyarlanarak üretken video canlandırmaya genişletilmiştir; bu katman yalnız işlerlik kanıtıdır (diskteki 7 render 22,3-41,8 sn) ve kıyaslanmamıştır. 115 terimlik çift-etiketleme kümesi üzerinde iki bağımsız değerlendirici ile Cohen'in kappa katsayısı hesaplanmış; bağlam uyumluluğunda κ_R = 0.782 (belirgin uyum), açıklama doğruluğunda ise κ_D = 1.000 elde edilmiştir (P_e ≈ 0,949 tekdüzeliği nedeniyle asıl ayırt edici gösterge κ_R'dir). Sonuç olarak doğruluk ve hız eşleştirmeleri dağıtılmış sistemler değil, ölçümlerden türetilmiş aday yapılardır: doğruluk için Whisper Large-v3 + GPT-4.1, yerel/hız için Whisper Turbo + Qwen3.5-4B (ölçülen klip başına 39,55 s, tepe cihaz doluluğu 5,26 GB). Öğrenme kazanımı bu çalışmada ölçülmemiştir.

Anahtar Kelimeler: Otomatik Konuşma Tanıma (ASR), Büyük Dil Modelleri (LLM), Terminoloji Çıkarma, Çok Dilli Eğitim Teknolojileri, Whisper, Qwen3-ASR, Cohen'in Kappa Katsayısı, Üç Katmanlı Değerlendirme.

Abstract

A Three-Layer Evaluation of Speech-to-Text, LLM-Based Terminology Extraction, and Generative Video-Animation Systems for Multilingual Education

Digital video-based instruction provides immense learning opportunities, yet specialized educational lectures inherently assume baseline domain familiarity, confronting beginner learners with substantial terminological friction. This graduation thesis presents a comprehensive, three-layer experimental evaluation of commercial and open-weight Automatic Speech Recognition (ASR), Large Language Model (LLM) and generative video-animation architectures for making multilingual (Turkish and English) educational lectures accessible. In the first layer, leading ASR systems (Whisper Medium, Large-v3, Large-v3 Turbo, Turkish-matched Turbo, Qwen3-ASR 0.6B / 1.7B, and NVIDIA Nemotron 3.5 ASR) are systematically benchmarked across raw/normalized Word Error Rate (WER), Character Error Rate (CER), latency, and Real-Time Factor (RTF). In the second layer, transcripts are fed to LLMs to extract domain-specific terminology and generate beginner-friendly, CEFR-B1 explanations. Evaluation references were established across 7 lectures (~95 minutes) via human-corrected gold transcripts. Human evaluation reliability was validated via double-annotated Cohen's kappa (N=115), achieving κ_R = 0.782 (substantial agreement on context consistency) and κ_D = 1.000 (definition accuracy; κ_D is a prevalence artefact at P_e ≈ 0.949, so κ_R is the discriminating statistic). A fixed-LLM ablation over clean Whisper hypotheses shows that semantic consistency does not collapse at low WER; feeding degraded front-ends into fixed Qwen3.5-4B is reported as a relational observation on single clips (TR-1 precision falls to 50.0%), not as a measured end-to-end error-propagation curve and not as causality. The measured acoustic interventions (energy VAD, terminology biasing, LLM post-correction) did not lower macro WER below the raw baseline on any of the 7 clips (TR 0.021 → 0.134), and the biasing stage leaks the gold term list. Finally, a third generative video-animation layer was built and is reported as a feasibility result only: the 7 renders on disk measure 22.3-41.8 s, and neither animation latency, audio-visual sync, gaze-tracking accuracy nor any learning outcome was measured. A local FastAPI-based interactive studio demonstrates the pipeline end to end; it is a PoC, not a deployed product.

Keywords: Automatic Speech Recognition, Large Language Models, Terminology Extraction, Multilingual Educational Technology, Whisper, Qwen3-ASR, Inter-Annotator Agreement, Error Propagation.

1. Giriş ve Problem Tanımı

1.1 Motivasyon

Eğitimin bireyselleştirilmesi, öğrencinin kavrama hızına ve hazırbulunuşluk düzeyine göre içeriğin uyarlanması, eğitim bilimlerinde uzun süredir en yüksek kazanımı sağlayan yöntem olarak bilinmektedir. Benjamin Bloom'un ünlü "2-Sigma Problemi" (1984), bire bir öğretmen rehberliğinde ustalık öğrenimi (mastery learning) gören öğrencilerin, geleneksel sınıf ortamındaki akranlarına kıyasla iki standart sapma daha başarılı olduğunu ortaya koymuştur. Ancak insan eğitmenlerle bire bir eğitim sunmak, devasa öğrenci kitleleri için sürdürülebilir ve ölçeklenebilir değildir.

Günümüzde çevrimiçi kitlesel açık dersler (MOOC), YouTube eğitim serileri ve dijital video platformları geniş kitlelere eğitim ulaştırmaktadır. Ancak bu videolardaki bilgi, ses sinyalinin içerisine gömülüdür. Başlangıç düzeyindeki bir öğrenci, videoda geçen teknik bir terimi ("çizelge sapması", "MICE turizmi", "Scrum backlog", "ANOVA testi" veya "kara cisim ışıması" gibi) bilmediğinde, videoyu durdurup harici kaynaklarda aramak zorunda kalmakta, bu da bilişsel yükü (cognitive load) artırmakta ve öğrenme akışını kesintiye uğratmaktadır.

1.2 Amaç ve Araştırma Soruları

Bu projenin temel amacı; sesli ve görüntülü eğitim içeriklerini anlayan, transkribe eden, içerisindeki zorlayıcı teknik terimleri tespit edip başlangıç düzeyindeki öğrencilerin anlayacağı seviyede (CEFR B1) otomatik açıklamalar üreten ve bu açıklamaları animasyonlu bir videoya dönüştürebilen üç katmanlı bir yapay zekâ boru hattını bilimsel titizlikle tasarlamak, ilk iki katmanını ölçerek değerlendirmek, üçüncüsünü işlerlik kanıtı olarak belgelemek ve çalışan bir yerel prototip stüdyosu haline getirmektir.

Çalışma kapsamında yanıt aranan temel araştırma soruları (Research Questions) şunlardır:

- RQ1 (ASR Doğruluğu ve Verimliliği): Güncel konuşma tanıma modelleri, Türkçe ve İngilizce eğitim konuşmalarında dil bazında ayrıştırıldığında hata oranı (WER/CER) ve hesaplama maliyeti (RTF, gecikme) açısından nasıl performans sergilemektedir?
- RQ2 (LLM Semantik Kapsamı ve Açıklama Kalitesi): Transkriptler verildiğinde, ticari dil modelleri (GPT-4.1) ile açık ağırlıklı modeller (GPT-4o-mini, Qwen3.5), terim yakalama kapsamı, bağlamsal tutarlılık (R1) ve sözlük doğruluğu (D1) açısından nasıl farklılaşmaktadır?
- RQ3 (Katmanlar Arası Eşleşme ve Dağıtım Tercihleri): Doğruluk-öncelikli ve hız/gecikme-öncelikli senaryolarda hangi ASR+LLM ikilileri tercih edilmelidir? Sabit bir açık ağırlıklı LLM (Qwen3.5-4B) farklı kalitedeki ASR transkriptleriyle beslendiğinde akustik hatalar semantik çıktıya nasıl yayılmaktadır?

2. Literatür Taraması (İlgili Çalışmalar)

2.1 Otomatik Konuşma Tanıma (ASR): Baevski ve ark. (2020) ham ses dalga formlarından özdenetimli gösterim öğrenen Wav2Vec 2.0 ve çok dilli türevi XLSR-53 mimarilerini sunmuştur. Radford ve ark. (OpenAI, 2023), 680.000 saatlik veriyle zayıf denetimli Whisper mimarisini geliştirmiştir. 2024 yılında sunulan Whisper Turbo ise dekoder katmanlarını 32'den 4'e düşürmüştür; üreticinin '8 kata varan hızlanma' ifadesi bir satıcı iddiasıdır — bu çalışmada aynı ana makinede ölçülen havuzlanmış duvar saati hızlanması Türkçede 3,4 kat, İngilizcede 7,7 kattır. 2026 yılında sunulan Qwen3-ASR (Alibaba) ve NVIDIA Nemotron 3.5 ise açık ağırlıklı çok dilli alternatifler olarak öne çıkmaktadır.

2.2 Otomatik Terminoloji Çıkarma (ATE): C-value/NC-value ve TF-IDF tabanlı istatistiksel yöntemlerden LiTeWi (Conde ve ark., 2016) gibi eğitimsel ontoloji çıkarma sistemlerine uzanan literatür, son dönemde büyük dil modellerinin (Tran ve ark., 2026) çok kelimeli terimleri bağlamsal esneklikle yakalama gücünü doğrulamıştır.

2.3 Uyarlanabilir Eğitim Sistemleri ve LLM Tutanları: Akıllı öğretim sistemleri (ITS) geleneksel olarak kurallar ve öğrenci modelleme algoritmalarıyla (Brusilovsky, 2007; VanLehn, 2011) çalışmıştır. Vanzo ve ark. (ACL 2025), GPT-4'ün öğrenci katılımını belirgin şekilde artırdığını deneysel olarak göstermiştir. Ancak literatürdeki çalışmalar temiz metin girdisi varsaymakta; ses sinyalinden terim çıkarımına uçtan uca hata yayılımını inceleyen çalışmalar son derece sınırlı kalmaktadır.

3. Sistem Mimarisi ve Yöntem

Çalışmada incelenen sistem üç işleme katmanından oluşur: ölçülen iki katman (ASR ve LLM) ile yalnız işlerlik kanıtı olarak değerlendirilen üçüncü katman (üretken video canlandırma). Katmanlar pratik bir gösterim ortamında etkileşimli bir yerel web stüdyosunda birleştirilir:



3.1 Katman 1 (ASR): Ses dosyaları 16 kHz mono PCM WAV standardına dönüştürülür (gürültü giderme, kesme veya elle ses düzenlemesi yapılmamıştır). Kıyaslama yolunda Whisper ailesi tüm ses üzerinde ardışık generate() ile koşar; sabit 30 saniyelik dilimleme yalnızca arayüz (GUI) yoluna ve Qwen3-ASR'ye aittir, Nemotron 60 saniyelik parçalar kullanır. Üretim bütçesi Whisper'ın 448'lik hedef konumuyla sınırlıdır (max_new_tokens=440; prompt_ids verildiğinde önek uzunluğu ve 16 belirteç düşülerek kırpılır). Çıktılar hem ham hem de normalize edilmiş biçimde saklanır.
3.2 Katman 2 (LLM): Transkript metni sabitlenmiş bir sistem yönlendirmesiyle (system prompt) LLM katmanına beslenir. Modelden ders bağlamına tam uyumlu teknik terimleri (çok kelimeli ifadeler dahil) tespit etmesi ve CEFR B1 düzeyinde sade bir tanım üretmesi istenir; çıktı kesin JSON formatında yapılandırılır.
3.3 Katman 3 (Üretken Video Canlandırma, işlerlik kanıtı): seçili terimin çevresindeki [t−45 sn, t+10 sn] bağlam penceresi yerel Qwen3.5-4B'ye verilir; model senaryo + Manim kodu üretir, ast allow-list denetimi ve azami 2 kendini-onarma denemesinden sonra manim -ql (480p15) + Edge-TTS + FFmpeg ile MP4 derlenir. Bu katman kıyaslanmamıştır; üretim gecikmesi, ses-görüntü senkronu ve öğrenme etkisi ölçülmemiştir.

4. Veri Kümesi ve Doğrulama Protokolü

Değerlendirme kümesi beş farklı disiplinden yedi hazırlanmış/senaryolu tek konuşmacılı eğitim videosundan derlenmiştir (yerel WAV'lar toplam 95,6 dk; altın referanslarda 13.467 kelime). Orijinal metindeki 'dengeli terminolojik yük' ifadesinin nasıl ölçüldüğü kayıtlı değildir ve bu çalışmada yeniden ölçülmemiştir; küme seçimi ölçülmüş bir yoğunluk dengesine değil, disiplin çeşitliliğine dayanır (experiments/data/DATASET_CARD.md):

Kod	Dil	Ders / Video Başlığı	Alan / Disiplin	Süre	Kelime
TR-1	TR	AÖF Proje Yönetimi — Ünite 7 Konu Anlatımı	Proje Yönetimi	12:01	1,256
TR-2	TR	Turist Rehberleri İçin Kapsamlı Turizm Eğitimi	Turizm	11:17	1,464
TR-3	TR	Tirendaz AI Veri Bilimi Nedir, Python	Veri Bilimi	14:15	1,583
EN-1	EN	Grow with Google: Intro to Agile Methodologies	Çevik Yöntemler	13:17	2,168
EN-2	EN	What is Sustainable Tourism? (Hayley Stainton)	Sürdürülebilir Turizm	09:16	1,267
EN-3	EN	Generative AI in a Nutshell (Henrik Kniberg)	Üretken Yapay Zekâ	17:57	3,459
EN-4	EN	Understanding Thermal Radiation (Efficient Eng.)	Isı Transferi / Fizik	17:33	2,270
Toplam	—	7 Video Dersi	5 Farklı Disiplin	95,6 dk	13,467

Akademik Dürüstlük Uyarısı: 'Bağımsız Gold Transkript' Yanılgısından Kaçınma

Referans transkriptler sıfırdan bağımsız bir insan transkripsiyonu değildir. EN-1 ve EN-4 insan üretimi altyazılara; TR-1, TR-2, EN-2 ve EN-3 YouTube otomatik altyazılarının dinlenerek teknik terimlerinin ve noktalamalarının insan eliyle düzeltilmesine (post-editing); TR-3 ise doğrudan sesten taslak çıkarılmasına dayanmaktadır. Bu durum, referansların otomatik altyazı ve Whisper stili sentaks/cümle bölme kalıplarına hafif bir stil yakınlığı taşımasına yol açabilmekte ve WER skorlarında marjinal bir avantaj sağlayabilmektedir. Bu kısıt jüriye tam bir akademik şeffaflıkla sunulmalıdır.

5. Değerlendirme Metrikleri ve İstatistiksel Güvenilirlik

5.1 ASR Metrikleri: Kelime Hata Oranı (WER = (S + D + I) / N), Karakter Hata Oranı (CER) ve Gerçek Zamanlılık Katsayısı (RTF = İşlem Süresi / Ses Süresi) hesaplanmıştır. Normalizasyonda Türkçedeki İ/i ve I/ı ayrımı korunmuştur.
5.2 Semantik Metrikler: Bağlamsal Tutarlılık (R1: terim ders bağlamına uygun mu?) ve Açıklama Doğruluğu (D1: tanım TDK/Oxford sözlüklerine göre doğru mu?) ölçülmüştür. Önemli: R1 skoru modelin ürettiği terimler üzerindeki bir kesinliktir (precision); kapalı altın sözlük olmadan tam bir recall ölçümü değildir.
5.3 İki Bağımsız Değerlendirici ve Cohen'in Kappa Analizi: 115 terimlik çift etiketli kümede:

- Bağlam Uyumluluğu (R): %96.5 ham uyum (111/115 terim, 4 uyumsuzluk), κ_R = 0.782 (Belirgin Uyum / Substantial Agreement). Varyans ve sınır vakaları içeren bu metrik, değerlendirici güvenilirliğini kanıtlayan asıl ayırt edici göstergedir.
- Açıklama Doğruluğu (D): %100.0 ham uyum, κ_D = 1.000 (Mükemmel Uyum). Ancak bu kümede 112 pozitif ve yalnızca 3 negatif etiket bulunduğundan, şans eseri beklenen uyum zaten $P_e \approx 0.95$ seviyesindedir (Kappa Paradoksu / Prevalence Paradox). Dolayısıyla κ_D = 1.000 matematiksel bir beklenen sonuç olup κ_R kadar zorlu bir ayrım gücü kanıtı değildir.

6. Deneysel Bulgular ve Karşılaştırmalı Analiz

6.1 ASR Katmanı Başarımı (GPU Altın Referanslar & Bootstrap Aralıkları)

ASR Modeli	Dil Kapsamı	TR Macro / Micro	TR 95% Bootstrap CI	EN Macro / Micro	EN 95% Bootstrap CI	Ort. RTF
Whisper Large-v3	tr+en	0.021 / 0.021	[0.014, 0.032]	0.010 / 0.010	[0.007, 0.012]	0.151–0.216
Whisper Turbo	tr+en	0.037 / 0.037	[0.011, 0.052]	0.011 / 0.012	[0.007, 0.017]	0.025–0.044
Whisper Medium	tr+en	0.049 / 0.050	[0.030, 0.081]	0.011 / 0.013	[0.007, 0.016]	0.296–0.321
Turkish Turbo (FT)	tr only	0.082 / 0.087	[0.035, 0.163]	---	---	0.076
Qwen3-ASR 0.6B	tr+en	0.134 / 0.136	[0.086, 0.180]	0.021 / 0.021	[0.013, 0.029]	0.118–0.180
Nemotron 3.5 ASR	tr+en	0.214 / 0.221	[0.117, 0.287]	0.035 / 0.034	[0.026, 0.049]	0.176–0.242

ASR Katmanı Çıkarımları: Whisper Large-v3 en düşük hata oranına (TR 0.021 / EN 0.010) sahipken; Whisper Turbo aynı ana makinede havuzlanmış duvar saati süresine göre Türkçede 3,4 kat (110,56 sn -> 32,53 sn), İngilizcede 7,7 kat (170,72 sn -> 22,10 sn) daha hızlı çıkarım yapmaktadır (ölçülen RTF 0,025 EN / 0,044 TR; bedeli Türkçede WER'in 0,021'den 0,037'ye çıkmasıdır). Üreticinin '4-8 kat' aralığı bu çalışmada ölçülmediği için burada kullanılmamıştır. Gerçek zamanlılık iddiası bu RTF ölçümüyle sınırlıdır: boru hattın uçtan uca etkileşim gecikmesi ölçülmemiştir. 10,000 örneklemeli bootstrap güven aralıkları, küçük örneklem boyutuna bağlı varyansı açıkça belgelemektedir.

6.2 Semantik Katman ve Kapalı Altın Recall (Ön Uç WER'si Sabit LLM ile Eşleştirildi)

TR-1 ve EN-1 dersleri için oluşturulan kapalı altın sözlükler (N=32 terim) üzerinden kesinlik, duyarlılık (recall) ve F1 skorları hesaplanmış; aynı LLM'i (Qwen3.5-4B) sabitleyip farklı ASR hipotezleri beslenerek ön uç hatası ile semantik kapsam arasındaki ilişkisel gözlem elde edilmiştir. Yedi kliplik küçüğümüzde ölçülmüş bir hata-yayılım eğrisi yoktur (WER'ı sistematik olarak bozulmuş girdiler üretip tekrar koşmadık); ayrıca kapsam WER'a monoton değildir: TR-1'de duyarlılık Large-v3 (0,016) için %25,0 iken Nemotron (0,117) için %28,1'dir:

ASR Ön Ucu	LLM Modeli	Ders	Çıkarılan	TP	Kesinlik	Duyarlılık	F1 Skoru	Ön Uç WER
Whisper Large-v3	Qwen3.5-4B	TR-1	12	8	66.7%	25.0%	36.4%	0.016 (Düşük WER)
Turkish Turbo (FT)	Qwen3.5-4B	TR-1	8	7	87.5%	21.9%	35.0%	0.035 (Orta WER)
Nemotron 3.5 ASR	Qwen3.5-4B	TR-1	9	9	100.0%	28.1%	43.9%	0.117 (Yüksek WER)
Qwen3-ASR 0.6B	Qwen3.5-4B	TR-1	10	5	50.0%	15.6%	23.8%	0.136 (En yüksek TR ön uç hatası)
Girdi loglanmadı †	Qwen3.5-9B	TR-1	16	15	93.8%	46.9%	62.5%	kayıtlı değil †
Whisper Large-v3	Qwen3.5-4B	EN-1	21	18	85.7%	56.2%	67.9%	0.006 (Düşük WER)
Qwen3-ASR 0.6B	Qwen3.5-4B	EN-1	18	16	88.9%	50.0%	64.0%	0.009 (Düşük WER)

İlişkisel gözlem, nedesellik değil: tek bir Türkçe klipte (TR-1) en yüksek ön uç hatasına sahip Qwen3-ASR 0.6B beslemesinde kesinlik %50.0'e, duyarlılık %15.6'ya gerilemiştir; bu, yüksek ASR hatasının semantik kapsamı zedeleyen eğilimiyle tutarlıdır. Ancak tek kliplik (TR-1) ve 32 terimlik kapalı listeyle bu bir yayılım eğrisi ya da nedesel kanıt değildir; nitekim aynı tabloda Nemotron (WER 0,117) Large-v3'ten (WER 0,016) daha yüksek duyarlılık (%28,1 / %25,0) vermektedir. † Qwen3.5-9B satırı:hangi transkriptin beslendiği outputs/llm-20260913-210556.jsonl içinde loglanmadığı için bu hücre bir ASR ön uç etkisi olarak okunamaz ve altın listeyle beslendiği de iddia edilmez; satır yalnız 9B'nin kapalı listeye göre çıkarım kapasitesini gösterir (kağıt üzerindeki karşılığı: tables/gold_recall.tex, 'Input not logged').

7. Donanım, Bellek Darboğazı ve Gecikme Profili

Tüm deneysel koşular tek bir tüketici sınıfı dizüstü iş istasyonunda gerçekleştirilmiştir; donanım ve yazılım imzaları experiments/check_env.py ile yeniden doğrulanabilir. Kuruma tahsis edilmiş bir laboratuvar kümesi veya eşdeğer iş istasyonu kullanılmamıştır:
• İşlemci: Intel Core i7-14650HX (16 Çekirdek, 24 İş Parçacığı, 5.2 GHz Turbo)
• Grafik İşlemci (GPU): NVIDIA GeForce RTX 5060 Laptop GPU (8 GB GDDR6 VRAM, CUDA 13.0)
• Sistem Belleği: 32 GB DDR5 • Yazılım: Windows 11 64-bit, Python 3.12, PyTorch 2.12.0+cu130, ReportLab 4.4+.

8 GB VRAM Tüketici Donanımında Gecikme Sonucu (ölçülmüş):
4-bit NF4 kuantize edilmiş Qwen3.5-4B modelinin ölçülen tepe cihaz doluluğu 5,26 GB (ağırlıklar 3,08 GB, torch ayırıcısı 4,72 GB; outputs/local_vram_probe.json) ve Large-v3 beslemesinde tam bir ders klibini 39.55 saniyede (s.d. 2.11 s, n=3 TR klibi) tamamlamaktadır. Qwen3.5-9B ise kayıtlı iki Türkçe klipte ortalama 513.19 saniyede (~8.6 dakika) koşmuştur (s.d. 269.97 s; 4B'nin 3 kliplik TR ortalamasına oranlandığında ~13 kat, ancak iki hücre farklı klip kümelerine dayanır). Bu koşuda 8 GB sınırının aşıldığı gözlenmiştir; kaç GB VRAM gerektirdiği ölçülmemiştir ve bu satır bir sunucu gereksinimi iddiası olarak okunmamalıdır. 9B'nin ürettiği terim listelerinin hangi transkript girdisinden geldiği llm-20260913-210556.jsonl içinde loglanmadığı için (%46.9 TR-1 duyarlılık hücresi) o değer bir ön uç etkisi olarak kullanılamaz.

Sonuç: tek 8 GB sınıfı dizüstü GPU'da 4B'nin klip başına onlarca saniyede koşabildiği ölçülmüştür; bu, dağıtılmış bir üretim tercihi değil, diskteki ölçüme dayanan bir aday yapılandırmadır.

8. Geliştirilen Yerel Demo Stüdyosu (`experiments/gui/`)

Boru hattının uçtan uca uygulanabilirliğini sergilemek amacıyla FastAPI ve modern cam efektli (glassmorphism) Vanilla CSS/JS arayüzünden oluşan bir yerel demo stüdyosu (`experiments/gui/`, `python run_gui.py`) geliştirilmiştir.
Temel Yetenekler: (a) `yt-dlp` ile YouTube video indirme; (b) doğrudan mikrofon kaydı ve yerel ses dosyası yükleme; (c) video oynatıcıyla senkronize transkripsiyon gösterimi; (d) CEFR B1 düzeyinde eşzamanlı dinamik terim kartları ve modeller arası yan yana karşılaştırma; (e) 'Takıldığım Yeri Öğret' ile Katman 3 animasyon üretimi (diskteki 7 ürün ffprobe ile 22,3-41,8 sn, 854x480@15; tasarım hedefi olan '30-90 sn' ölçülmüş bir çıktı özelliği değildir ve üretim çevrimdışı/batch'tir).
Not: Bu arayüz ticari bir SaaS ürünü değil, açık CORS ve bellek içi iş kuyruğu kullanan yerel bir konsept kanıtlama (PoC) stüdyosudur. Webcam göz takibi kolu kodda vardır (getUserMedia + MediaPipe FaceMesh, CDN'den yüklenir; kamera yoksa simülasyon moduna düşer ve sekme/pencere odağı ayrı bir dikkat sinyali üretir), ancak bakış doğruluğu ve oto-duraklamanın etkisi ölçülmemiştir; kareler kişisel veridir (KVKK/GDPR) ve tarayıcıda kalır. GUI, Bölüm 6.1.1'de ölçülen enerji VAD parçalayıcısını kullanmaz (sabit 30 sn dilim, gui/pipeline.py). Öğrenme kazanımı bu çalışmada ölçülmemiştir.

9. Sonuç, Kısıtlar ve Aday Yapılandırma Önerileri

9.1 Aday Boru Hattı Eşleştirmeleri: aşağıdaki satırlar dağıtılmış sistemler değil, diskteki ölçümlerden türetilmiş önerilerdir; hiçbirinin yük testi, eşzamanlı oturum testi veya saha değerlendirmesi yapılmamıştır.
1. Yerel / Uç Cihaz Adayı: Whisper Turbo + Qwen3.5-4B → ölçülen RTF 0,025 (EN) / 0,044 (TR). Aşama ortalamalarının toplamı klip başına ~95 sn TR (32,53 sn ASR + 62,90 sn LLM) ve ~117 sn EN (22,10 sn + 94,60 sn); bu aşama toplamlarıdır, uçtan uca ölçülmüş etkileşim gecikmesi değildir. Sıfır harici API maliyeti ve ölçülen 5,26 GB tepe cihaz doluluğu (outputs/local_vram_probe.json).
2. Doğruluk Adayı: Whisper Large-v3 + GPT-4.1 → en düşük WER (0,021 TR / 0,010 EN) ve EN-1'de ölçülen en yüksek duyarlılık (%56,2; Qwen3.5-4B ile). Qwen3.5-9B'nin %46,9'luk TR-1 hücresi girdi dizimi loglanmadığı için bu adayın dayanağı değildir ve 9B'nin ihtiyaç duyduğu VRAM ölçülmemiştir; '16 GB gerekir' tipi bir sayısal eşik iddia edilmez.
3. Akustik ön-işleme önerilmez: enerji VAD, terim koşullama ve LLM düzeltme yedi klipte makro WER'i ham tabanın altına indirmedi (TR 0,021 → 0,041 → 0,082 → 0,134); koşullama kademesi altın listeyi prompt_ids ile beslediği için ayrıca sızıntıdır (outputs/interventions_summary.json).

9.2 Temel Kısıtlar: (1) Veri kümesi 7 video (95 dk) ile sınırlıdır; (2) Referanslar bağımsız çift-kör transkripsiyon değil, insan düzeltmeli taslaklardır; (3) Dil modellerinin duyarlılığı yalnızca TR-1 ve EN-1'deki kapalı altın sözlükler üzerinde ölçülebilmiştir; (4) κ_D = 1.000 skoru yüksek sınıf tekdüzeliği (prevalence, P_e ≈ 0,949) nedeniyle κ_R = 0.782 kadar güçlü bir ayrım göstergesi değildir; (5) kayıtların hiçbirinde akustik nicelik ölçülmedi, dolayısıyla klip zorluğu açıklanmış değil gözlenmiş bir özelliktir; (6) LLM hakem ile insan etiketi arasında bir uyum/doğrulama testi yoktur, R1/D1 hakem-üretimi sayıdır; (7) Katman 3 yalnız işlerlik kanıtıdır — üretim gecikmesi, ses-görüntü senkronu ve öğrenme etkisi ölçülmemiştir.

9.3 Gelecek Çalışmalar: Açık kaynaklı bir LMS (Moodle/Canvas) eklentisine dönüştürülmesi ve öğrencinin öğrenme geçmişini takip eden bir Bilgi Takip (Knowledge Tracing) modülü ile tam uyarlanabilir bir öğretici asistana evrilmesi planlanmaktadır.

10. Kaynakça

- Bloom, B. S. (1984). "The 2 sigma problem: The search for methods of group instruction as effective as one-to-one tutoring." Educational Researcher, 13(6), 4-16.
- Radford, A., Kim, J. W., Xu, T., et al. (2023). "Robust speech recognition via large-scale weak supervision." Proc. ICML, 28492-28518.
- Wang, X., et al. (2026). "Qwen3-ASR technical report." arXiv preprint arXiv:2601.21337.
- NVIDIA (2026). "Nemotron 3.5 ASR streaming 0.6B model card." Hugging Face Hub.
- Conde, A., Larrañaga, M., et al. (2016). "LiTeWi: A combined term extraction and entity linking method for eliciting educational ontologies from textbooks." JASIST, 67(2), 380-399.
- Tran, H. T. H., Martinc, M., et al. (2026). "Recent advances in automatic term extraction: A comprehensive survey." ACM Computing Surveys, 58(9), 1-35.
- Vanzo, A., Pal Chowdhury, S., & Sachan, M. (2025). "GPT-4 as a homework tutor can improve student engagement and learning outcomes." Proc. ACL, 31119-31136.
- Cohen, J. (1960). "A coefficient of agreement for nominal scales." Educational and Psychological Measurement, 20(1), 37-46.
- Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). "wav2vec 2.0: A framework for self-supervised learning of speech representations." NeurIPS, 33, 12449-12460.
- Ravanelli, M., et al. (2021). "SpeechBrain: A general-purpose speech toolkit." arXiv:2106.04624.