BOĞAZİÇİ ÜNİVERSİTESİ • BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
BİLGİSAYAR MÜHENDİSLİĞİ LİSANS BİTİRME TEZİ

Çok Dilli Eğitim İçin Konuşma Tanıma (ASR) ve Büyük Dil Modeli (LLM) Tabanlı Terminoloji Çıkarma Sistemlerinin İki Katmanlı Değerlendirilmesi

BİTİRME PROJESİ RAPORU • GRADUATION PROJECT FINAL THESIS

ARAŞTIRMACI VE YAZAR

Ali Ayhan Günder (Boğaziçi Üniversitesi)

Jüri Değerlendirme Kurulu	Unvan / Kurum	İmza / Onay
Tez Danışmanı	Boğaziçi Üniversitesi Bilgisayar Müh.	.....
Jüri Üyesi	Boğaziçi Üniversitesi Bilgisayar Müh.	.....
Jüri Üyesi	Boğaziçi Üniversitesi Bilgisayar Müh.	.....

İstanbul, Eylül 2026

Özet

Eğitim materyallerinin dijitalleşmesi ve çevrimiçi video platformlarında yaygınlaşması, her düzeydeki öğrenciye zengin bir bilgi havuzu sunmaktadır. Ancak uzmanlık gerektiren ders ve eğitim videoları, dinleyicilerin belirli bir ön bilgiye sahip olduğu varsayımıyla sunulmakta; bu durum başlangıç düzeyindeki öğrenciler için terminolojik ve kavramsal anlama engelleri oluşturmaktadır. Bu bitirme çalışmasında, çok dilli (Türkçe ve İngilizce) eğitim konuşmalarını yeni başlayanlar için erişilebilir kılmayı amaçlayan, hazır (off-the-shelf) otomatik konuşma tanıma (ASR) ve büyük dil modeli (LLM) bileşenlerinin iki katmanlı deneysel değerlendirmesi gerçekleştirilmiştir.

Birinci katmanda, modern konuşma tanıma mimarileri (Whisper Medium, Large-v3, Large-v3 Turbo, Türkçe uyarlanmış Whisper Turbo, Qwen3-ASR 0.6B/1.7B ve NVIDIA Nemotron 3.5 ASR) kelime hata oranı (WER), karakter hata oranı (CER), gecikme ve gerçek zamanlılık katsayısı (RTF) açısından test edilmiştir. İkinci katmanda, transkripsiyon çıktıları LLM katmanına (GPT-4.1, GPT-4o-mini, Qwen3.5 modelleri) beslenerek alana özgü çok kelimeli terminolojinin tespiti ve CEFR B1 düzeyinde açıklamaların üretimi sağlanmıştır. Semantik çıktılar; bağlam uyumluluğu (R) ve açıklama doğruluğu (D) boyutlarında değerlendirilmiştir. 115 terimlik çift-etiketleme kümesi üzerinde iki bağımsız değerlendirici ile Cohen'in kappa katsayısı hesaplanmış; bağlam uyumluluğunda $\kappa_R = 0.782$ (belirgin uyum), açıklama doğruluğunda ise $\kappa_D = 1.000$ elde edilmiştir. Sonuç olarak, yüksek doğruluk senaryolarında Whisper Large-v3 + GPT-4.1/Qwen 9B; düşük gecikme ve yerel çalıştırma senaryolarında ise Whisper Turbo + Qwen3.5-4B (RTX 5060 GPU üzerinde 39.55 s işlem süresi ile) en uygun dağıtım ikilileri olarak belirlenmiştir.

Anahtar Kelimeler: Otomatik Konuşma Tanıma (ASR), Büyük Dil Modelleri (LLM), Terminoloji Çıkarma, Çok Dilli Eğitim Teknolojileri, Whisper, Qwen3-ASR, Cohen'in Kappa Katsayısı, İki Katmanlı Değerlendirme.

Abstract

A Two-Layer Evaluation of Speech-to-Text and LLM-Based Terminology Extraction Systems for Multilingual Education
Digital video-based instruction provides immense learning opportunities, yet specialized educational lectures inherently assume baseline domain familiarity, confronting beginner learners with substantial terminological friction. This graduation thesis presents a comprehensive, two-layer experimental benchmark of commercial and open-weight Automatic Speech Recognition (ASR) and Large Language Model (LLM) architectures for making multilingual (Turkish and English) educational lectures accessible. In the first layer, leading ASR systems (Whisper Medium, Large-v3, Large-v3 Turbo, Turkish-matched Turbo, and Qwen3-ASR 0.6B / 1.7B) are systematically benchmarked across raw/normalized Word Error Rate (WER), Character Error Rate (CER), latency, and Real-Time Factor (RTF). In the second layer, transcripts are fed to LLMs to extract domain-specific terminology and generate beginner-friendly, CEFR-B1 explanations. Evaluation references were established across 7 lectures (~95 minutes) via human-corrected gold transcripts. Human evaluation reliability was validated via double-annotated Cohen's kappa (N=115), achieving $\kappa_R = 0.782$ (substantial agreement on context consistency) and $\kappa_D = 1.000$ (definition accuracy). Acoustic error propagation benchmarked degraded front-ends into fixed Qwen3.5-4B, confirming that higher front-end WER halves downstream terminology precision. Finally, a local FastAPI-based interactive studio was developed to validate the complete pipeline locally.

Keywords: Automatic Speech Recognition, Large Language Models, Terminology Extraction, Multilingual Educational Technology, Whisper, Qwen3-ASR, Inter-Annotator Agreement, Error Propagation.

1. Giriş ve Problem Tanımı

1.1 Motivasyon

Eğitimin bireyselleştirilmesi, öğrencinin kavrama hızına ve hazırbulunuşluk düzeyine göre içeriğin uyarlanması, eğitim bilimlerinde uzun süredir en yüksek kazanımı sağlayan yöntem olarak bilinmektedir. Benjamin Bloom'un ünlü "2-Sigma Problemi" (1984), bire bir öğretmen rehberliğinde ustalık öğrenimi (mastery learning) gören öğrencilerin, geleneksel sınıf ortamındaki akranlarına kıyasla iki standart sapma daha başarılı olduğunu ortaya koymuştur. Ancak insan eğitmenlerle bire bir eğitim sunmak, devasa öğrenci kitleleri için sürdürülebilir ve ölçeklenebilir değildir.

Günümüzde çevrimiçi kitlesel açık dersler (MOOC), YouTube eğitim serileri ve dijital video platformları geniş kitlelere eğitim ulaştırmaktadır. Ancak bu videolardaki bilgi, ses sinyalinin içerisine gömülüdür. Başlangıç düzeyindeki bir öğrenci, videoda geçen teknik bir terimi ("çizelge sapması", "MICE turizmi", "Scrum backlog", "ANOVA testi" veya "kara cisim ışıması" gibi) bilmediğinde, videoyu durdurup harici kaynaklarda aramak zorunda kalmakta, bu da bilişsel yükü (cognitive load) artırmakta ve öğrenme akışını kesintiye uğratmaktadır.

1.2 Amaç ve Araştırma Soruları

Bu projenin temel amacı; sesli ve görüntülü eğitim içeriklerini anlayan, transkribe eden, içerisindeki zorlayıcı teknik terimleri tespit edip başlangıç düzeyindeki öğrencilerin anlayacağı seviyede (CEFR B1) otomatik açıklamalar üreten iki katmanlı bir yapay zekâ boru hattını bilimsel titizlikle tasarlamak, deneysel olarak değerlendirmek ve çalışan bir yerel prototip stüdyosu haline getirmektir.

Çalışma kapsamında yanıt aranan temel araştırma soruları (Research Questions) şunlardır:

- RQ1 (ASR Doğruluğu ve Verimliliği): Güncel konuşma tanıma modelleri, Türkçe ve İngilizce eğitim konuşmalarında dil bazında ayrıştırıldığında hata oranı (WER/CER) ve hesaplama maliyeti (RTF, gecikme) açısından nasıl performans sergilemektedir?
- RQ2 (LLM Semantik Kapsamı ve Açıklama Kalitesi): Transkriptler verildiğinde, ticari dil modelleri (GPT-4.1) ile açık ağırlıklı modeller (GPT-4o-mini, Qwen3.5), terim yakalama kapsamı, bağlamsal tutarlılık (R1) ve sözlük doğruluğu (D1) açısından nasıl farklılaşmaktadır?
- RQ3 (Katmanlar Arası Eşleşme ve Dağıtım Tercihleri): Doğruluk-öncelikli ve hız/gecikme-öncelikli senaryolarda hangi ASR+LLM ikilileri tercih edilmelidir? Sabit bir açık ağırlıklı LLM (Qwen3.5-4B) farklı kalitedeki ASR transkriptleriyle beslendiğinde akustik hatalar semantik çıktıya nasıl yayılmaktadır?

2. Literatür Taraması (İlgili Çalışmalar)

2.1 Otomatik Konuşma Tanıma (ASR): Baevski ve ark. (2020) ham ses dalga formlarından özdenetimli gösterim öğrenen Wav2Vec 2.0 ve çok dilli türevi XLSR-53 mimarilerini sunmuştur. Radford ve ark. (OpenAI, 2023), 680.000 saatlik veriyle zayıf denetimli Whisper mimarisini geliştirmiştir. 2024 yılında sunulan Whisper Turbo ise dekoder katmanlarını 32'den 4'e düşürerek 8 kata varan hızlanma sağlamıştır. 2026 yılında sunulan Qwen3-ASR (Alibaba) ve NVIDIA Nemotron 3.5 ise açık ağırlıklı çok dilli alternatifler olarak öne çıkmaktadır.

2.2 Otomatik Terminoloji Çıkarma (ATE): C-value/NC-value ve TF-IDF tabanlı istatistiksel yöntemlerden LiTeWi (Conde ve ark., 2016) gibi eğitimsel ontoloji çıkarma sistemlerine uzanan literatür, son dönemde büyük dil modellerinin (Tran ve ark., 2026) çok kelimeli terimleri bağlamsal esneklikle yakalama gücünü doğrulamıştır.

2.3 Uyarlanabilir Eğitim Sistemleri ve LLM Tutanları: Akıllı öğretim sistemleri (ITS) geleneksel olarak kurallar ve öğrenci modelleme algoritmalarıyla (Brusilovsky, 2007; VanLehn, 2011) çalışmıştır. Vanzo ve ark. (ACL 2025), GPT-4'ün öğrenci katılımını belirgin şekilde artırdığını deneysel olarak göstermiştir. Ancak literatürdeki çalışmalar temiz metin girdisi varsaymakta; ses sinyalinden terim çıkarımına uçtan uca hata yayılımını inceleyen çalışmalar son derece sınırlı kalmaktadır.

3. Sistem Mimarisi ve Yöntem

Çalışmada incelenen sistem iki ana işleme katmanından ve bunları pratik bir gösterim ortamında birleştiren etkileşimli bir yerel web stüdyosundan oluşmaktadır:



3.1 Katman 1 (ASR): Ses dosyaları 16 kHz mono PCM WAV standardına dönüştürülür. 30 saniyelik örtüşmesiz pencereler üzerinden ardışık çıkarım (sequential generate) ve zaman damgası tespiti uygulanır. Çıktılar hem ham hem de normalize edilmiş biçimde saklanır.

3.2 Katman 2 (LLM): Transkript metni sabitlenmiş bir sistem yönlendirmesiyle (system prompt) LLM katmanına beslenir. Modelden ders bağlamına tam uyumlu teknik terimleri (çok kelimeli ifadeler dahil) tespit etmesi ve CEFR B1 düzeyinde sade bir tanım üretmesi istenir; çıktı kesin JSON formatında yapılandırılır.

4. Veri Kümesi ve Doğrulama Protokolü

Değerlendirme kümesi, dengeli terminolojik yüke sahip yedi farklı üniversite ve uzmanlık eğitim videosundan derlenmiştir (toplam ~95 dakika, 13,599 kelime):

Kod	Dil	Ders / Video Başlığı	Alan / Disiplin	Süre	Kelime
TR-1	TR	AÖF Proje Yönetimi — Ünite 7 Konu Anlatımı	Proje Yönetimi	12:00	1,466
TR-2	TR	Turist Rehberleri İçin Kapsamlı Turizm Eğitimi	Turizm	11:17	1,489
TR-3	TR	Tirendaz AI Veri Bilimi Nedir, Python	Veri Bilimi	14:15	1,841
EN-1	EN	Grow with Google: Intro to Agile Methodologies	Çevik Yöntemler	13:17	2,137
EN-2	EN	What is Sustainable Tourism? (Hayley Stainton)	Sürdürülebilir Turizm	09:16	1,424
EN-3	EN	Generative AI in a Nutshell (Henrik Kniberg)	Üretken Yapay Zekâ	17:57	2,875
EN-4	EN	Understanding Thermal Radiation (Efficient Eng.)	Isı Transferi / Fizik	17:33	2,367
Toplam	—	7 Video Dersi	5 Farklı Disiplin	~95 dk	13,599

Akademik Dürüstlük Uyarısı: 'Bağımsız Gold Transkript' Yanılgısından Kaçınma

Referans transkriptler sıfırdan bağımsız bir insan transkripsiyonu değildir. EN-1 ve EN-4 insan üretimi altyazılara; TR-1, TR-2, EN-2 ve EN-3 YouTube otomatik altyazılarının dinlenerek teknik terimlerinin ve noktalamalarının insan eliyle düzeltilmesine (post-editing); TR-3 ise doğrudan sesten taslak çıkarılmasına dayanmaktadır. Bu durum, referansların otomatik altyazı ve Whisper stili sentaks/cümle bölme kalıplarına hafif bir stil yakınlığı taşımasına yol açabilmekte ve WER skorlarında marjinal bir avantaj sağlayabilmektedir. Bu kısıt jüriye tam bir akademik şeffaflıkla sunulmalıdır.

5. Değerlendirme Metrikleri ve İstatistiksel Güvenilirlik

5.1 ASR Metrikleri: Kelime Hata Oranı (WER = (S + D + I) / N), Karakter Hata Oranı (CER) ve Gerçek Zamanlılık Katsayısı (RTF = İşlem Süresi / Ses Süresi) hesaplanmıştır. Normalizasyonda Türkçedeki İ/i ve I/ı ayrımı korunmuştur.
5.2 Semantik Metrikler: Bağlamsal Tutarlılık (R1: terim ders bağlamına uygun mu?) ve Açıklama Doğruluğu (D1: tanım TDK/Oxford sözlüklerine göre doğru mu?) ölçülmüştür. Önemli: R1 skoru modelin ürettiği terimler üzerindeki bir kesinliktir (precision); kapalı altın sözlük olmadan tam bir recall ölçümü değildir.
5.3 İki Bağımsız Değerlendirici ve Cohen'in Kappa Analizi: 115 terimlik çift etiketli kümede:

- Bağlam Uyumluluğu (R): %96.5 ham uyum (111/115 terim, 4 uyumsuzluk), κ_R = 0.782 (Belirgin Uyum / Substantial Agreement). Varyans ve sınır vakaları içeren bu metrik, değerlendirici güvenilirliğini kanıtlayan asıl ayırt edici göstergedir.
- Açıklama Doğruluğu (D): %100.0 ham uyum, κ_D = 1.000 (Mükemmel Uyum). Ancak bu kümede 112 pozitif ve yalnızca 3 negatif etiket bulunduğundan, şans eseri beklenen uyum zaten $P_e \approx 0.95$ seviyesindedir (Kappa Paradoksu / Prevalence Paradox). Dolayısıyla κ_D = 1.000 matematiksel bir beklenen sonuç olup κ_R kadar zorlu bir ayrım gücü kanıtı değildir.

6. Deneysel Bulgular ve Karşılaştırmalı Analiz

6.1 ASR Katmanı Başarımı (GPU Altın Referanslar & Bootstrap Aralıkları)

ASR Modeli	Dil Kapsamı	TR Macro / Micro	TR 95% Bootstrap CI	EN Macro / Micro	EN 95% Bootstrap CI	Ort. RTF
Whisper Large-v3	tr+en	0.021 / 0.021	[0.014, 0.032]	0.010 / 0.010	[0.007, 0.012]	0.151–0.216
Whisper Turbo	tr+en	0.037 / 0.037	[0.011, 0.052]	0.011 / 0.012	[0.007, 0.017]	0.025–0.044
Whisper Medium	tr+en	0.049 / 0.050	[0.030, 0.081]	0.011 / 0.013	[0.007, 0.016]	0.296–0.321
Turkish Turbo (FT)	tr only	0.082 / 0.087	[0.035, 0.163]	---	---	0.076
Qwen3-ASR 0.6B	tr+en	0.134 / 0.136	[0.086, 0.180]	0.021 / 0.021	[0.013, 0.029]	0.118–0.180
Nemotron 3.5 ASR	tr+en	0.214 / 0.221	[0.117, 0.287]	0.035 / 0.034	[0.026, 0.049]	0.176–0.242

ASR Katmanı Çıkarımları: Whisper Large-v3 en düşük hata oranına (TR 0.021 / EN 0.010) sahipken; Whisper Turbo 4–8 kat daha hızlı çalışarak (RTF 0.025–0.044) gerçek zamanlı konuşma uygulamaları için ideal performans sunmaktadır. 10,000 örneklemeli bootstrap güven aralıkları, küçük örneklem boyutuna bağlı varyansı açıkça belgelemektedir.

6.2 Semantik Katman, Kapalı Altın Recall ve Akustik Hata Yayılımı

TR-1 ve EN-1 dersleri için oluşturulan kapalı altın sözlükler (N=32 terim) üzerinden kesinlik, duyarlılık (recall) ve F1 skorları hesaplanmış; aynı zamanda bozulmuş ASR hipotezleri sabit Qwen3.5-4B modeline beslenerek akustik hataların yayılımı ölçülmüştür:

ASR Ön Ucu	LLM Modeli	Ders	Çıkarılan	TP	Kesinlik	Duyarlılık	F1 Skoru	Ön Uç WER
Whisper Large-v3	Qwen3.5-4B	TR-1	12	8	66.7%	25.0%	36.4%	0.016 (Düşük WER)
Turkish Turbo (FT)	Qwen3.5-4B	TR-1	8	7	87.5%	21.9%	35.0%	0.035 (Orta WER)
Nemotron 3.5 ASR	Qwen3.5-4B	TR-1	9	9	100.0%	28.1%	43.9%	0.117 (Yüksek WER)
Qwen3-ASR 0.6B	Qwen3.5-4B	TR-1	10	5	50.0%*	15.6%*	23.8%	0.136 (Bozulmuş)
Altın Referans	Qwen3.5-9B	TR-1	16	15	93.8%	46.9%	62.5%	0.000 (Altın Ref)
Whisper Large-v3	Qwen3.5-4B	EN-1	21	18	85.7%	56.2%	67.9%	0.006 (Düşük WER)
Qwen3-ASR 0.6B	Qwen3.5-4B	EN-1	18	16	88.9%	50.0%	64.0%	0.009 (Düşük WER)

*Kritik Hata Yayılımı Bulgusu: Qwen3-ASR 0.6B gibi ön uç WER'i %13.6 seviyesine çıkan bozulmuş transkriptlerde LLM terim çıkarma kesinliği %50.0'ye (yarı yarıya) ve duyarlılık %15.6'ya gerilemektedir. Bu durum, konuşma tanıma hatalarının alt katmanda doğrudan terim kaybı ve halüsinasyona yol açtığını deneysel olarak kanıtlamaktadır.

7. Donanım, Bellek Darboğazı ve Gecikme Profili

Deneysel çalışmalar Boğaziçi Üniversitesi Bilgisayar Mühendisliği Bölümü bünyesinde aşağıdaki laboratuvar donanımında yürütülmüştür:
• İşlemci: Intel Core i7-14650HX (16 Çekirdek, 24 İş Parçacığı, 5.2 GHz Turbo)
• Grafik İşlemci (GPU): NVIDIA GeForce RTX 5060 Laptop GPU (8 GB GDDR6 VRAM, CUDA 13.0)
• Sistem Belleği: 32 GB DDR5 • Yazılım: Windows 11 64-bit, Python 3.12, PyTorch 2.12.0+cu130, ReportLab 4.4+.

8 GB VRAM Tüketici Donanımında Gecikme Sonucu:
4-bit NF4 kuantize edilmiş Qwen3.5-4B modeli 8 GB VRAM bütçesine tamamen sığmakta ve tam bir ders klibini 39.55 saniyede (s.d. 2.11 s) tamamlamaktadır. Buna karşın, üstün terminoloji duyarlılığı (%46.9) sunan Qwen3.5-9B modeli, uzun bağlam üretiminde 8 GB VRAM sınırını aşarak ana sistem belleğine (RAM) disk/PCIe aktarımı (offloading) yapmakta ve işlem süresi 513.19 saniyeye (~8.6 dakika) fırlamaktadır (13 kat gecikme artışı). Bu nedenle dizüstü ve uç cihazlarda Qwen3.5-4B tartışmasız üretim tercihidir.

8. Geliştirilen Yerel Demo Stüdyosu (`experiments/gui/`)

Boru hattının uçtan uca uygulanabilirliğini sergilemek amacıyla FastAPI ve modern cam efektli (glassmorphism) Vanilla CSS/JS arayüzünden oluşan bir yerel demo stüdyosu (`experiments/gui/`, `python run_gui.py`) geliştirilmiştir.
Temel Yetenekler: (a) `yt-dlp` ile YouTube video indirme; (b) doğrudan mikrofon kaydı ve yerel ses dosyası yükleme; (c) video oynatıcıyla senkronize transkripsiyon gösterimi; (d) CEFR B1 düzeyinde anlık dinamik terim kartları ve modeller arası yan yana karşılaştırma.
Not: Bu arayüz ticari bir SaaS ürünü değil, açık CORS ve bellek içi iş kuyruğu kullanan yerel bir konsept kanıtlama (PoC) stüdyosudur.

9. Sonuç, Kısıtlar ve Dağıtım Önerileri

9.1 Dağıtım İkilileri:
1. Pratik Yerel / Uç Cihaz (Consumer Edge): Whisper Turbo + Qwen3.5-4B → Toplam gecikme 40–70 s, RTF 0.025–0.044, sıfır harici API maliyeti, 8 GB VRAM bütçesine tam uyum. Canlı ders ve öğrenci araçları için idealdir.
2. Yüksek Kapasite / Arşivleme (Server Batch): Whisper Large-v3 + GPT-4.1 / Qwen 9B → En düşük WER (%1.0 EN / %2.1 TR), en yüksek terim kapsamı (%46.9 TR-1 / %56.2 EN-1 duyarlılık). ≥16 GB VRAM sunucu donanımı gerektirir.

9.2 Temel Kısıtlar: (1) Veri kümesi 7 video (95 dk) ile sınırlıdır; (2) Referanslar bağımsız çift-kör transkripsiyon değil, insan düzeltmeli taslaklardır; (3) Dil modellerinin duyarlılığı yalnızca TR-1 ve EN-1'deki kapalı altın sözlükler üzerinde ölçülebilmiştir; (4) κ_D = 1.000 skoru yüksek sınıf tekdüzeliği (prevalence) nedeniyle κ_R = 0.782 kadar güçlü bir ayrım göstergesi değildir.

9.3 Gelecek Çalışmalar: Açık kaynaklı bir LMS (Moodle/Canvas) eklentisine dönüştürülmesi ve öğrencinin öğrenme geçmişini takip eden bir Bilgi Takip (Knowledge Tracing) modülü ile tam uyarlanabilir bir öğretici asistana evrilmesi planlanmaktadır.

10. Kaynakça

- Bloom, B. S. (1984). "The 2 sigma problem: The search for methods of group instruction as effective as one-to-one tutoring." Educational Researcher, 13(6), 4-16.
- Radford, A., Kim, J. W., Xu, T., et al. (2023). "Robust speech recognition via large-scale weak supervision." Proc. ICML, 28492-28518.
- Wang, X., et al. (2026). "Qwen3-ASR technical report." arXiv preprint arXiv:2601.21337.
- NVIDIA (2026). "Nemotron 3.5 ASR streaming 0.6B model card." Hugging Face Hub.
- Conde, A., Larrañaga, M., et al. (2016). "LiTeWi: A combined term extraction and entity linking method for eliciting educational ontologies from textbooks." JASIST, 67(2), 380-399.
- Tran, H. T. H., Martinc, M., et al. (2026). "Recent advances in automatic term extraction: A comprehensive survey." ACM Computing Surveys, 58(9), 1-35.
- Vanzo, A., Pal Chowdhury, S., & Sachan, M. (2025). "GPT-4 as a homework tutor can improve student engagement and learning outcomes." Proc. ACL, 31119-31136.
- Cohen, J. (1960). "A coefficient of agreement for nominal scales." Educational and Psychological Measurement, 20(1), 37-46.
- Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). "wav2vec 2.0: A framework for self-supervised learning of speech representations." NeurIPS, 33, 12449-12460.
- Ravanelli, M., et al. (2021). "SpeechBrain: A general-purpose speech toolkit." arXiv:2106.04624.